

UNITAT 9 · SETMANES 15–16

SO natiu per a la IA: agents i LLM al sistema operatiu

 Setmanes 15–16 · dates per confirmar
  Laboratori TD8 (resolt + repte IA)

 4 animacions

MANUAL M9 · TEORIA DE LA UNITAT

SO natiu per a la IA: agents i LLM al sistema operatiu

Lectura bàsica de la unitat 9 ($\approx 1,5$ h). Aquesta unitat ajunta tot el curs: un agent d'IA és un procés més, que fa servir crides al sistema, fitxers, memòria, fils i sòcols, però les decisions del qual les pren un model que es pot equivocar. **Els productes citats canvien de pressa:** cada afirmació porta la seva font i data (comprovades el 25/09/2026).

CONTINGUT

- | | | | |
|----|------------------------------------|----|-------------------------------------|
| §1 | Del xat a l'agent | §4 | Les primitives d'aïllament de Linux |
| §2 | Què han anunciat Windows i Linux | §5 | El model proposa, el SO disposa |
| §3 | La inferència com a càrrega del SO | | |

§1 Del xat a l'agent

Un model de llenguatge (LLM) rep text i prediu el text següent. Un **agent** hi afegix un bucle: el model proposa una *acció* —una crida a una eina, com `read_file("notas.txt")`—, un programa l'executa i el resultat torna al model. Així un assistent pot ordenar fitxers, canviar la configuració o escriure en una aplicació.

Per al sistema operatiu això és nou per dues raons: l'agent actua **en nom de l'usuari però no és l'usuari**, i les seves decisions surten d'un model estadístic que es pot equivocar o ser manipulat (per exemple, amb instruccions amagades en un document que s'anomena *injecció de prompt*). Per això les preguntes d'aquesta unitat són preguntes de sistema operatiu: qui és l'agent?, què pot tocar?, qui l'autoritza?, com s'audita?

§2 Què han anunciat Windows i Linux

Windows

- **Agent workspace:** un espai separat on l'agent treballa en paral·lel amb l'usuari, amb **el seu propi compte**; accedeix a les carpetes conegudes (Documents, Baixades, Escriptori, Música,

Imatges, Vídeos) només si l'usuari ho activa i hi dona el consentiment. S'activa a *Configuració* → *Sistema* → *Components d'IA* → *Funcions agèntiques experimentals* (versió preliminar).

Font: Microsoft Support, «Experimental agentic features».

- **Agent connectors:** servidors *Model Context Protocol* (MCP) que connecten l'agent amb aplicacions i eines del sistema, registrats a l'**On-Device Registry**; els primers, per a l'Explorador de fitxers i la Configuració (Insiders, desembre de 2025). Fonts: Microsoft Support; The Register, 08/12/2025.
- Principis declarats: accions de l'agent **observables i distingibles** de les de l'usuari, **autorització** de l'usuari per a dades i accions, i **mínim privilegi** (mai més permisos que l'usuari que l'ha engegat).
- **Microsoft Execution Containers** (Build 2026, 2 de juny de 2026): una capa d'execució amb polítiques declaratives per a agents a Windows i WSL, amb aïllament per *procés*, per *sessió* o en una *micro-VM* recolzada en l'hipervisor; en versió preliminar inicial. Font: Windows Developer Blog, «Windows platform security for AI agents», 02/06/2026.

Linux

- No hi ha un únic «agent del sistema»: el **nucli ofereix primitives** (§4) i les distribucions i aplicacions les combinen.
- **Canonical (Ubuntu)** va anunciar el 2026 funcions d'IA centrades en la inferència local amb models oberts (*inference snaps*) i agents confinats amb mecanismes de snap; les primeres versions preliminars s'esperen a Ubuntu 26.10. No hi haurà un interruptor global d'IA: es desactiva traient els snaps. Fonts: OMG! Ubuntu, 04/2026; Phoronix.
- Per als acceleradors d'IA, Linux té el subsistema **accelel** (controladors de NPU d'Intel i AMD). A la comunitat del nucli, des de desembre de 2025 la documentació demana declarar l'ajuda d'eines d'IA amb l'etiqueta **Assisted-by**; només una persona pot afegir la signatura **Signed-off-by**.

Practica-ho → animació A9.1 · Arquitectura d'un SO agèntic

§3 La inferència com a càrrega del SO

Per al sistema operatiu, executar un model és un programa amb un perfil molt particular:

- **Pesos enormes i de només lectura.** Es carreguen amb **mmap** (unitat 6): no es copien, sinó que es llegeixen de la memòria cau de pàgines quan es toquen (fallades de pàgina), i diversos processos comparteixen les mateixes pàgines físiques. El micro-LLM del TD8 mapa així els seus ≈ 0,7 MB de pesos.
- **La memòria cau KV.** Per a cada token ja processat, el model guarda les claus i els valors de cada capa per no tornar-los a calcular: memòria que creix amb la longitud de la conversa (al TD8, $2 \times \text{capes} \times \text{context} \times 64 \times 4 \text{ bytes}$).
- **Dues fases.** El *prefill* processa tota la petició de cop; el *decode* genera un token per pas, i cada pas llegeix tots els pesos.

- **Acceleradors.** Les GPU i les NPU es gestionen com a dispositius: controladors, memòria pròpia i planificació de l'accés entre processos.

Practica-ho → animació A9.2 · Dins del micro-LLM

§4 Les primitives d'aïllament de Linux

PRIMITIVA	QUÈ LIMITA	NECESSITA ROOT
Usuaris i permisos	Fitxers segons propietari, grup i mode	Per crear usuaris
Landlock (des de la 5.13)	Quins camins del sistema de fitxers pot obrir el procés; ports TCP (ABI 4); senyals i sòcols abstractes fora del seu àmbit (ABI 6)	No: el procés es restringeix a si mateix
seccomp	Quines crides al sistema pot fer	No (amb <code>no_new_privs</code>)
Namespaces	Què veu: processos, muntatges, xarxa, usuaris (la base dels contenidors)	No, amb namespaces d'usuari
cgroups	Quant consumeix: CPU, memòria, E/S	Normalment sí (o delegat per systemd)
<code>setrlimit</code>	Límits per procés: temps de CPU, mida de fitxer, descriptors	No, per abaixar-los

El TD8 fa servir Landlock, `setrlimit` i `alarm` a `agent_exec`: després de `landlock_restrict_self` el procés ja no pot sortir de l'espai de treball, encara que el seu propi codi ho intenti. La restricció s'hereta i no es pot desfer.

§5 El model proposa, el SO disposa

La lliçó central de la unitat: **la sortida del model és text no fiable**. El SO agèntic del TD8 la tracta com qualsevol entrada externa:

1. **Analitzador estricte:** només `name("arg", "arg")` d'un catàleg tancat; tota la resta es rebutja.
2. **Política:** camins relatius dins de l'espai de treball, sense `..` i resolent els enllaços simbòlics (`realpath`).
3. **Consentiment** de l'usuari per a qualsevol cosa destructiva.
4. **Entorn aïllat del nucli** (Landlock) com a última línia: si la política falla o està desactivada, el nucli igualment denega l'accés.
5. **Auditoria:** cada decisió va a `audit.log` amb l'uid i el pid del client (`SO_PEERCREd`).

És el principi de *defensa en profunditat*: cap capa no confia que l'anterior no hagi fallat.

Practica-ho → animació A9.4 · El model proposa, el SO disposa, i TD8