



Universidad
Indoamérica

UNITAT 9 · FONAMENTS DE SISTEMES OPERATIUS

El model proposa, el sistema operatiu disposa

Universidad Tecnológica Indoamérica

SO natiu per a la IA

Del xat a l'agent

LLM

Text → text següent.

Agent

Text → **acció** (eina) → resultat → text...

- Actua en nom de l'usuari, però **no és l'usuari**.
- Es pot equivocar amb tota seguretat o ser enganyat (injecció de prompt).

Cinc responsabilitats, tres plataformes

delete old_report.pdf

TD8 (aquest curs)

usuari

agent (LLM)

crida a eina

SO: decideix

fitxer / app

Identitat de l'agent

sòcol UNIX 0600 + SO_PEERCRED (uid i pid del client)

Eines (connectors)

catàleg tancat d'11 eines; analitzador estricte

Consentiment

agentd pregunta abans de delete_file

Aïllament

fork + exec d'agent_exec: setrlimit, alarm i Landlock

Auditoria

audit.log amb O_APPEND: una línia per decisió

Windows com a SO agèntic

- **Agent workspace** amb un compte propi de l'agent (versió preliminar)
- **Agent connectors**: servidors MCP a l'**On-Device Registry** (Insiders, des. 2025)
- Principis: accions distingibles, autorització de l'usuari, mínim privilegi
- **Microsoft Execution Containers** (Build 2026): procés · sessió · micro-VM

Fonts i dates: manual M9 §2.

Linux: peces per muntar

Landlock

camins i xarxa, sense root

seccomp

quines crides

namespaces

· cgroups

què veu · quant consumeix

Distribucions: Ubuntu anuncia *inference snaps* i agents confinats (versions preliminars a la 26.10).


Maquinari: el subsistema `accele` per a NPU.

Un LLM per dins: bytes, memòria cau KV, atenció


petició i resposta, byte a byte

Q : _ s h o w _ m e _ n o t a s . t x t ↵ A : _ r e a d _ f
i l e ("

mapa d'atenció: una fila per pas, una columna per byte



byte següent: els 5 més probables



```
read_file("I
```

174.656 paràmetres en C, mesurats pel SO

Sortida real

```
$ ./tinylm -v "lista los archivos de docs"
""
list_files("docs")

model      : 174656 parameters, 3 layers, 4 heads, d=64, context 128 bytes
weights    : 698688 bytes mapped with mmap (MAP_PRIVATE, PROT_READ)
KV cache   : 201984 bytes per request (+ scratch)
tokens     : 33 of prompt (prefill) + 19 generated (decode)
time       : load 0.042 ms, inference 9.08 ms (5730 tokens/s)
page faults: 2 during load, 47 during the first inference (minor; major: 0)
```

- Els pesos es **mapen** (unitat 6): carregar-los triga dècimes de mil·lisegon i 2 fallades de pàgina; la resta arriben quan es fan servir (unitat 4)
- La memòria cau KV és memòria **per petició**; els pesos els comparteixen tots

Encertar el 99 % de les vegades no n'hi ha prou

v1

99,4 % de coincidència exacta a la seva prova... però al laboratori va convertir `viejo.txt` en `viefe.txt` : havia vist pocs noms com aquest.

v2

El mateix model de 3 capes (174.656 paràmetres), però dades amb noms més variats i 12.000 passos en lloc de 10.000: 99,0 % en 500 peticions noves, i copia bé els noms rars.

Un 1 % d'errors sobre milers d'accions són desenes d'accions equivocades: per això el SO **no es fia** de la sortida del model (§5).

La inferència, tal com la veu el SO

PEÇA	UNITAT DEL CURS
Pesos amb <code>mmap</code> , compartits	U6
Fallades de pàgina en tocar els pesos	U4
Memòria cau KV que creix per token	U4
Un fil per petició en un grup	U7
NPU / GPU com a dispositius	U1 · U3
L'agent parla amb <code>agentd</code> per un sòcol local	U8

La inferència com a càrrega del SO

micro-LLM (TD8) · mesurat

codi de tinyllm

heap: memòria cau KV + espai de treball

52 / 128 posicions · 78,0 KiB

mmap: fitxer de pesos (només lectura)



171 pàgines de 4 KiB · 47 fallades en fer-les servir

pila

memòria per a 8 agent(s)

pesos compartits (mmap)



1,3 MiB

cada agent copia els pesos



6,0 MiB

pesos memòria cau KV

una petició: 33 tokens d'entrada (prefill) + 19 generats · 9,08 ms en total



≈ 175 µs per token en un nucli


El SO agèntic del curs

Diagrama

```
agent —(sòcol UNIX 0600)→ agentd — grup de 8 fils
                        | SO_PEERCREG: qui crida (U8)
                        | tinyllm (mmap dels pesos, memòria cau KV)
                        | analitzador estricte → política → consentiment
                        ▼
fork + exec agent_exec
            | setrlimit · alarm · no_new_privs
            | Landlock: només workspace/ i /proc (lectura)
            ▼
eina → resultat → audit.log
```

Defensa en profunditat

petició:read atajo



línia que agentd afegeix a audit.log:

```
2026-09-25T10:00:00 uid=1000 pid=4242 request="read atajo" call=read_file("atajo") decision=deny outcome=error (Permission denied)
```

TD8 + repte IA

Bash

```
# peticions en anglès: el micro-LLM només entén castellà i anglès
cd tds/bin/td8 && mkdir -p workspace && echo hello > workspace/notes.txt
./agentd -w workspace &
./agent "show me notes.txt"
./agent "delete /etc/passwd"
cat audit.log
```

Repte: afegeix `copy_file` (dades, reentrenament, política, executor) i dissenya 5 atacs.



Universidad
Indoamérica

PER EMPORTAR-TE

Tres preguntes

1. Quines cinc responsabilitats exigeix un agent al SO?
2. Per què la sortida del model és «text no fiable»?
3. Quina capa atura l'enllaç trampós si la política falla?